

Taller 2.2b Aplicación matricial en un Análisis de Componentes Principales - PCA

Versión con código tidyverse y figuras en ggplot2

Nombre del Estudiante

18/8/26

Tabla de contenido

2. Aplicaciones de matrices (Análisis de Componentes Principales - PCA)	2
2.1 Librerías requeridas	2
Directorio para guardar tablas y figuras	2
2.2 Cargar base de datos (datos1.csv)	2
2.3 Cálculo de la matriz centrada	4
2.4 Valores y vectores propios	5
2.5 Matriz rotada y pca	6
2.6 Varianza explicada por cada componente	6
2.8 pca de forma automatizada	9
2.9 Coordenadas de estudiantes y de las variables morfométricas	9
2.10 Biplot del PCA automatizado (ggplot2)	10
Guardar la figura	11
Cuestionario de repaso	11

Nota: Quitar el formato «Cambria» de las tablas. En algunos casos, los títulos de las tablas pueden generar problemas en el renderizado del pdf, por lo que es mejor colocarlas como referencias cruzadas.

Probar colocando algunas citas bibliográficas y referencias cruzadas de tablas y figuras, para entrenar este procedimiento.

2. Aplicaciones de matrices (Análisis de Componentes Principales - PCA)

2.1 Librerías requeridas

```
# install.packages(c("kableExtra","ggplot2","ggrepel","GGally"))

# Librerías o paquetes requeridos
library(tidyverse)
library(ggplot2)      # Componente gráfico
library(ggrepel)      # Etiquetas de texto que no se superponen
library(GGally)       # Matriz de dispersión (ggpairs) - versión ggplot2 de
plot(matriz)
library(vegan)         # Para el pca de forma automatizada
library(kableExtra)    # Para la edición de las tablas
library(readxl)
library(writexl)
```

Directorio para guardar tablas y figuras

```
dir.create("outputs/figuras",
          recursive = TRUE,
          showWarnings = FALSE)
dir.create("outputs/tablas",
          recursive = TRUE,
          showWarnings = FALSE)
```

2.2 Cargar base de datos (datos1.csv)

```
# 1) Cargar la base de datos de Excel *.xlsx y dejarla lista en un solo bloque
tidyverse
datos <- read_xlsx("datos1.xlsx", sheet = "datos1 - copia") %>%
  drop_na() %>%      # Elimina al estudiante 13 (dato faltante)
  rename(Nombre = 1, Sexo = 2, LTot = 3, Cint = 4, LEsp = 5, LBra = 6)
```

```
glimpse(datos)      # Estructura de la base de datos (equivalente tidyverse de
str())
```

Rows: 24

Columns: 6

```
$ Nombre <chr> "Alumno 1", "Alumno 2", "Alumno 3", "Alumno 4", "Alumno 5", "Al~
$ Sexo   <chr> "F", "F", "F", "F", "M", "M", "M", "M", "M", "M", "F", "F", "F"~
$ LTot   <dbl> 170, 160, 156, 173, 170, 165, 170, 181, 175, 186, 168, 155, 158~
$ Cint   <dbl> 85, 80, 88, 63, 86, 89, 88, 80, 76, 45, 65, 70, 72, 79, 68, 68,~
$ LEsp   <dbl> 43, 41, 35, 53, 47, 45, 56, 60, 55, 60, 49, 36, 40, 43, 39, 38,~
$ LBra   <dbl> 57, 54, 48, 59, 56, 61, 59, 55, 54, 86, 55, 50, 55, 82, 50, 70,~
```

```
# CTRL + SHIFT + M (%>%)
datos %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)
```

Nombre	Sexo	LTot	Cint	LEsp	LBra
Alumno 1	F	170	85	43	57
Alumno 2	F	160	80	41	54
Alumno 3	F	156	88	35	48
Alumno 4	F	173	63	53	59
Alumno 5	M	170	86	47	56
Alumno 6	M	165	89	45	61
Alumno 7	M	170	88	56	59
Alumno 8	M	181	80	60	55
Alumno 9	M	175	76	55	54
Alumno 10	M	186	45	60	86
Alumno 11	F	168	65	49	55
Alumno 12	F	155	70	36	50
Alumno 14	F	158	72	40	55
Alumno 15	M	172	79	43	82
Alumno 16	F	155	68	39	50
Alumno 17	F	163	68	38	70
Alumno 18	M	170	122	48	60
Alumno 19	F	157	60	36	69
Alumno 20	F	162	60	50	76
Alumno 21	M	170	82	55	56

Alumno 22	F	158	75	35	60
Alumno 23	M	174	87	51	56
Alumno 24	F	170	88	37	78
Alumno 25	F	162	68	37	53

```
# Guardar tabla directorio principal
write_xlsx(datos, path = "datos_grales.xlsx")

# 5. Exportar a Excel para el anexo
write_xlsx(datos, "outputs/tablas/datos_grales.xlsx")
```

2.3 Cálculo de la matriz centrada

```
# Selección de las variables morfométricas con dplyr
variables <- datos %>%
  select(LTot:LBra)

# glimpse(variables)

promedio <- colMeans(variables)
round(promedio, 2)
```

```
LTot  Cint  LEsp  LBra
166.67 76.83 45.38 60.79
```

```
# El centrado es una operación matricial (no una operación "tidy"),
# por eso se deja explícita con álgebra de matrices
m.centrada <- t(t(variables) - promedio)

# Encabezado de la matriz centrada con las seis primeras filas
head(round(m.centrada, 2)) %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)
```

LTot	Cint	LEsp	LBra
3.33	8.17	-2.38	-3.79
-6.67	3.17	-4.38	-6.79
-10.67	11.17	-10.38	-12.79

6.33	-13.83	7.62	-1.79
3.33	9.17	1.62	-4.79
-1.67	12.17	-0.38	0.21

2.4 Valores y vectores propios

```
# Matriz centrada de covarianzas (S.centrada)
S.centrada <- var(m.centrada)
round(S.centrada, 2)
```

```
      LTot  Cint  LEsp  LBra
LTot 68.41  4.38 56.35 32.75
Cint  4.38 221.19 -3.67 -45.99
LEsp 56.35 -3.67 67.20 11.26
LBra 32.75 -45.99 11.26 108.95
```

```
# Valores y vectores propios de la S.centrada (vv.propios)
vv.propios <- eigen(S.centrada)
vv.propios
```

eigen() decomposition

\$values

```
[1] 238.551229 141.646198 77.460019 8.092554
```

\$vectors

```
      [,1]      [,2]      [,3]      [,4]
[1,] -0.06532082 -0.6446607 0.2348736 0.72455510
[2,]  0.93124818 -0.2601970 -0.2459119 -0.06783569
[3,] -0.06460934 -0.5458245 0.5144348 -0.65822342
[4,] -0.35261262 -0.4677453 -0.7872220 -0.19276967
```

```
# Vectores propios (vec.propios)
vec.propios <- vv.propios$vectors
vec.propios
```

```
      [,1]      [,2]      [,3]      [,4]
[1,] -0.06532082 -0.6446607 0.2348736 0.72455510
```

```
[2,] 0.93124818 -0.2601970 -0.2459119 -0.06783569
[3,] -0.06460934 -0.5458245 0.5144348 -0.65822342
[4,] -0.35261262 -0.4677453 -0.7872220 -0.19276967
```

2.5 Matriz rotada y pca

```
# Matriz centrada en formato matricial
m.centrada <- as.matrix(m.centrada)

# pca = matriz rotada (m.rotada)
m.rotada <- m.centrada %*% vec.propios
colnames(m.rotada) <- c("CP1", "CP2", "CP3", "CP4")

# Encabezado de la matriz rotada con las seis primeras filas
head(round(m.rotada, 2)) %>%
  kbl(booktabs = TRUE, digits = 2,
      longtable = TRUE) %>%
  kable_classic(full_width = F)
```

CP1	CP2	CP3	CP4
8.88	-1.20	0.54	4.16
6.06	9.04	0.75	-0.86
16.28	15.62	-0.52	0.81
-13.16	-3.81	10.22	0.85
9.90	-3.18	3.14	1.65
11.39	-1.98	-3.74	-1.83

```
# Se convierte la matriz a tibble y se une con Nombre y Sexo
# para poder graficarla con ggplot2 en las siguientes secciones
pca_manual <- m.rotada %>%
  as_tibble() %>%
  bind_cols(datos %>% select(Nombre, Sexo))
```

2.6 Varianza explicada por cada componente

```
varianza <- tibble(
  Componente = factor(paste0("CP", seq_along(vv.propios$values)),
    levels = paste0("CP",
      seq_along(vv.propios$values))),
```

```

    Valor_propio = vv.propios$values,
    Porc_varianza = 100 * vv.propios$values / sum(vv.propios$values)
  )

  varianza

```

```


# A tibble: 4 x 3
  Componente Valor_propio Porc_varianza
  <fct>         <dbl>         <dbl>
1 CP1           239.           51.2
2 CP2           142.           30.4
3 CP3            77.5           16.6
4 CP4            8.09           1.74

```

```


ggplot(varianza, aes(x = Componente, y = Porc_varianza)) +
  geom_col(fill = "#3BBDD9", color = "black") +
  geom_line(aes(group = 1), color = "firebrick", linewidth = 0.8) +
  geom_point(color = "firebrick", size = 2) +
  geom_text(aes(label = paste0(round(Porc_varianza, 1), "%")),
            vjust = -0.8, size = 3.5) +
  labs(x = "Componente principal", y = "Varianza explicada (%)",
       title = "Varianza explicada por cada componente principal") +
  theme_minimal()

```



```
# Figura CP1 vs CP2 (versión ggplot2 del plot() + text() + abline() + grid())
ggplot(pca_manual, aes(x = CP1, y = CP2, color = Sexo)) +
  geom_point(size = 3) +
  geom_text_repel(aes(label = Nombre), size = 3, show.legend = FALSE) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "blue") +
  geom_vline(xintercept = 0, linetype = "dashed", color = "blue") +
  coord_fixed(ratio = 2) +
  labs(x = "Eje 1 (CP1)", y = "Eje 2 (CP2)",
       title = "PCA manual: proyección de los estudiantes sobre CP1 y CP2") +
  theme_bw()
```


PCA manual: proyección de los estudiantes sobre CI



2.8 pca de forma automatizada

```
# Nuevamente el pca, ahora con la función prcomp
pca <- prcomp(datos %>% select(LTot:LBra))
# summary(pca)
names(pca)
```

```
[1] "sdev"      "rotation" "center"    "scale"     "x"
```

2.9 Coordenadas de estudiantes y de las variables morfométricas

```
# Coordenadas de los estudiantes, con Nombre y Sexo reales (no el número de fila)
coord.estud <- as_tibble(pca$x[, 1:2]) %>%
  mutate(estudiante = datos$Nombre,
         sexo       = datos$Sexo)

head(coord.estud)
```

```
# A tibble: 6 x 4
  PC1    PC2 estudiante sexo
  <dbl> <dbl> <chr>      <chr>
1  8.88 -1.20 Alumno 1    F
2  6.06  9.04 Alumno 2    F
3 16.3  15.6 Alumno 3    F
4 -13.2 -3.81 Alumno 4    F
5  9.90 -3.18 Alumno 5    M
6 11.4  -1.98 Alumno 6    M

# Coordinadas de las variables morfométricas (dos primeros ejes)
coord.var <- as_tibble(pca$rotation[, 1:2]) %>%
  mutate(variables = rownames(pca$rotation))

coord.var
```

```
# A tibble: 4 x 3
  PC1    PC2 variables
  <dbl> <dbl> <chr>
1 -0.0653 -0.645 LTot
2  0.931  -0.260 Cint
3 -0.0646 -0.546 LEsp
4 -0.353  -0.468 LBra
```

2.10 Biplot del PCA automatizado (ggplot2)

```
pca_fig <-
ggplot() +
  # Estudiantes, coloreados por sexo
  geom_point(data = coord.estud, aes(PC1, PC2, color = sexo), size = 3) +
  geom_text_repel(data = coord.estud, aes(PC1, PC2, label = estudiante), size
    = 3.5) +
  # Variables morfométricas (flechas rojas)
  geom_segment(data = coord.var, aes(x = 0, y = 0, xend = PC1 * 20, yend = PC2
    * 20),
    arrow = arrow(angle = 22.5, length = unit(0.25, "cm"), type =
      "closed"),
    linetype = 1, linewidth = 0.6, colour = "red") +
  geom_text_repel(data = coord.var, aes(PC1 * 20, PC2 * 20, label = variables),
    colour = "red") +
  geom_hline(yintercept = 0, linetype = 3, linewidth = 0.8) +
  geom_vline(xintercept = 0, linetype = 3, linewidth = 0.8) +
```

```
labs(x = "CP1", y = "CP2", color = "Sexo",
     title = "Biplot PCA automatizado: estudiantes y variables
     morfométricas") +
theme_bw() +
theme(panel.grid = element_blank())

print(pca_fig)
```




Figura 1: Ordenación de los estudiantes y las variables morfométricas.

Guardar la figura

```
ggsave("outputs/figuras/pca_fig.png",
       pca_fig, width = 8, height = 5, dpi = 300)
```

Cuestionario de repaso

Estas preguntas son para trabajar en casa. No tienen una única respuesta «correcta» en el sentido de una ponderación.

1. ¿Por qué es necesario centrar los datos (restar el promedio de cada variable) antes de calcular la matriz de covarianza en un PCA? ¿Qué pasaría con los resultados si no se centraran?
2. Usando `S.centrada`, verificar en R que el primer vector propio corresponde efectivamente al valor propio más grande. Luego relacionar ese valor propio con el porcentaje de varianza explicada por CP1 que se calculó en la sección 2.6.
3. En el biplot final (estudiantes + variables morfométricas), ¿qué significa que dos flechas de variables (por ejemplo `LTot` y `Cint`) apunten en direcciones muy parecidas? ¿Y qué significaría que apuntaran en direcciones opuestas?
4. Escoger dos estudiantes que queden muy separados en el eje CP1 del biplot. Revisar sus medidas morfométricas originales (`LTot`, `Cint`, `LEsp`, `LBra`) en la base de datos. ¿Qué variable(s) explican mejor por qué quedaron tan separados?
5. Si tuviera que resumir a cada estudiante con un solo número en vez de con las cuatro medidas originales, ¿usaría CP1, CP2, o alguna combinación? Justificar su respuesta con el porcentaje de varianza explicada de cada componente.