

Taller 2.2b Analisis discriminante lineal - lda, con datos morfométricos en estudiantes

Versión con código tidyverse y figuras en ggplot2

Nombre del Estudiante

18/8/26

Tabla de contenido

2.1 Cargar librerías	2
2.2 Cargar la base de datos	2
2.3 Matrices por cada sexo	3
2.4 Vectores de medias por cada sexo	4
2.5 Matriz de covarianza generalizada invertida (S-1)	5
2.6 Discriminante lineal de Wald y Anderson (W)	7
3. Discriminante - lda con Tidyverse	8
3.1 Vectores de media	9
3.2 Función para automatizar el lda	10
3.3 Tabla de contingencia	11
3.4 Componente gráfico	11
3.5 Comparación con la función automatizada MASS::lda()	13
Cuestionario de repaso	15

Nota: Quitar el formato «Cambria» de las tablas. En algunos casos, los títulos de las tablas pueden generar problemas en el renderizado del pdf, por lo que es mejor colocarlas como referencias cruzadas.

Probar colocando algunas citas bibliográficas y referencias cruzadas de tablas y figuras, para entrenar este procedimiento.

2.1 Cargar librerías

```
# install.packages(c("kableExtra","patchwork"))

# Librerías o paquetes requeridos (se dejan todas aquí, al inicio)
library(tidyverse)
library(ggplot2)
library(vegan)
library(MASS)
library(kableExtra)
library(patchwork) # Para combinar figuras ggplot2 (reemplaza a
gridExtra/grid.arrange)
library(readxl)    # Para leer datos1.xlsx

# Nota: MASS también tiene una función select(), y como se carga después de
# tidyverse, "tapa" a dplyr::select(). Por eso en este documento se escribe
# siempre dplyr::select() de forma explícita, para evitar ese conflicto.
```

2.2 Cargar la base de datos

```
# 2.2 Cargar la base de datos (datos1.xlsx) - misma fuente que el taller de PCA
datos2 <- read_xlsx("datos1.xlsx", sheet = "datos1 - copia") %>%
  rename(Nombre = 1, Sexo = 2, LTot = 3, Cint = 4, LEsp = 5, LBra = 6) %>%
  drop_na() # Elimina estudiantes con datos faltantes
  (estud. 13)

glimpse(datos2) # Estructura de la base de datos (equivalente tidyverse de
str())
```

Rows: 24

Columns: 6

```
$ Nombre <chr> "Alumno 1", "Alumno 2", "Alumno 3", "Alumno 4", "Alumno 5", "Al~
$ Sexo   <chr> "F", "F", "F", "F", "M", "M", "M", "M", "M", "M", "F", "F", "F"~
$ LTot   <dbl> 170, 160, 156, 173, 170, 165, 170, 181, 175, 186, 168, 155, 158~
$ Cint   <dbl> 85, 80, 88, 63, 86, 89, 88, 80, 76, 45, 65, 70, 72, 79, 68, 68,~
```

```
$ LEsp <dbl> 43, 41, 35, 53, 47, 45, 56, 60, 55, 60, 49, 36, 40, 43, 39, 38,~
$ LBra <dbl> 57, 54, 48, 59, 56, 61, 59, 55, 54, 86, 55, 50, 55, 82, 50, 70,~
```

```
head(datos2) %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)
```

Nombre	Sexo	LTot	Cint	LEsp	LBra
Alumno 1	F	170	85	43	57
Alumno 2	F	160	80	41	54
Alumno 3	F	156	88	35	48
Alumno 4	F	173	63	53	59
Alumno 5	M	170	86	47	56
Alumno 6	M	165	89	45	61

2.3 Matrices por cada sexo

a) Opción general

```
# Matriz de hombres (hombres)
hombres <- datos2[datos2$Sexo == "M",]

head(hombres) %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)
```

Nombre	Sexo	LTot	Cint	LEsp	LBra
Alumno 5	M	170	86	47	56
Alumno 6	M	165	89	45	61
Alumno 7	M	170	88	56	59
Alumno 8	M	181	80	60	55
Alumno 9	M	175	76	55	54
Alumno 10	M	186	45	60	86

b) Opción en tidyverse

```
# Matriz de hombres (hombres)
hombres <- datos2 %>%
```

```
filter(Sexo == "M")

head(hombres) %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)
```

Nombre	Sexo	LTot	Cint	LEsp	LBra
Alumno 5	M	170	86	47	56
Alumno 6	M	165	89	45	61
Alumno 7	M	170	88	56	59
Alumno 8	M	181	80	60	55
Alumno 9	M	175	76	55	54
Alumno 10	M	186	45	60	86

```
# Matriz de mujeres (mujeres)
mujeres <- datos2 %>%
  filter(Sexo == "F")

head(mujeres) %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)
```

Nombre	Sexo	LTot	Cint	LEsp	LBra
Alumno 1	F	170	85	43	57
Alumno 2	F	160	80	41	54
Alumno 3	F	156	88	35	48
Alumno 4	F	173	63	53	59
Alumno 11	F	168	65	49	55
Alumno 12	F	155	70	36	50

2.4 Vectores de medias por cada sexo

```
# Vector de medias de los hombres (promedio.h)
# dplyr::select(LTot:LBra) evita depender de la posición de las columnas (más
robusto que [,2:5])
promedio.h <- hombres %>%
  dplyr::select(LTot:LBra) %>%
  colMeans()
```

```
promedio.h
```

```
LTot  Cint  LEsp  LBra
173.3  83.4  52.0  62.5
```

```
# Vector de medias de las mujeres (promedio.m)
promedio.m <- mujeres %>%
  dplyr::select(LTot:LBra) %>%
  colMeans()
promedio.m
```

```
LTot  Cint  LEsp  LBra
161.92857  72.14286  40.64286  59.57143
```

```
# Vector de diferencia de medias (dif)
dif <- promedio.h - promedio.m
t.dif <- t(dif)
t.dif
```

```
LTot  Cint  LEsp  LBra
[1,] 11.37143 11.25714 11.35714 2.928571
```

```
# Vector de suma de medias (suma)
# Nota: se renombra "sum" -> "suma" para no usar el mismo nombre de la función
base sum()
suma <- promedio.h + promedio.m
suma
```

```
LTot  Cint  LEsp  LBra
335.22857 155.54286  92.64286 122.07143
```

2.5 Matriz de covarianza generalizada invertida (S-1)

```
# Covarianza de hombres (cov.h)
cov.h <- var(hombres %>%
  dplyr::select(LTot:LBra))
```

```
round(cov.h, 2) %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)
```

	LTot	Cint	LEsp	LBra
LTot	37.57	-79.02	27.11	30.17
Cint	-79.02	347.16	-57.00	-116.89
LEsp	27.11	-57.00	37.11	-5.22
LBra	30.17	-116.89	-5.22	134.28

```
# Covarianza de mujeres (cov.m)
cov.m <- var(mujeres %>%
  dplyr::select(LTot:LBra))
round(cov.m, 2)
```

```
      LTot  Cint  LEsp  LBra
LTot 36.99   5.01 22.97 22.12
Cint  5.01  94.13 -24.41 -15.24
LEsp 22.97 -24.41 35.32   8.60
LBra 22.12 -15.24  8.60  95.96
```

```
# Tamaño de la muestra (No de estudiantes por cada sexo)
datos2$Sexo <- as.factor(datos2$Sexo)
summary(datos2$Sexo)
```

```
F  M
14 10
```

```
# Matriz de varianza-covarianza generalizada (ponderada por grados de libertad
n-1)
# Se calcula n.h y n.m dinámicamente en vez de escribir 10, 14 y 24 "a mano":
# así el código no se rompe si cambia el número de estudiantes
n.h <- nrow(hombres)
n.m <- nrow(mujeres)

cov.g <- ((n.h - 1) * cov.h + (n.m - 1) * cov.m) / (n.h + n.m - 2)
cov.g.i <- solve(cov.g)

round(cov.g.i, 3) %>%
```

```
kbl(booktabs = TRUE, longtable = TRUE) %>%
kable_classic(full_width = FALSE)
```

	LTot	Cint	LEsp	LBra
LTot	0.067	-0.004	-0.048	-0.016
Cint	-0.004	0.008	0.010	0.005
LEsp	-0.048	0.010	0.071	0.014
LBra	-0.016	0.005	0.014	0.015

2.6 Discriminante lineal de Wald y Anderson (W)

```
# Convertir datos2 a formato matricial, solo variables numéricas (datos3)
datos3 <-
  datos2 %>%
  dplyr::select(LTot:LBra) %>%
  as.matrix()

head(datos3) %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)
```

LTot	Cint	LEsp	LBra
170	85	43	57
160	80	41	54
156	88	35	48
173	63	53	59
170	86	47	56
165	89	45	61

```
# Vectores de los estudiantes (xi) - se calcula "a mano" para los primeros 10
estudiantes
x1 <- as.vector(datos3[1,])
x2 <- as.vector(datos3[2,])
x3 <- as.vector(datos3[3,])
x4 <- as.vector(datos3[4,])
x5 <- as.vector(datos3[5,])
x6 <- as.vector(datos3[6,])
x7 <- as.vector(datos3[7,])
x8 <- as.vector(datos3[8,])
```

```

x9 <- as.vector(datos3[9,])
x10 <- as.vector(datos3[10,])

# Correr el modelo lda para los 10 estudiantes
# t.dif, suma, xi, cov.g.i
W1 <- ((t.dif %>% cov.g.i %>% x1) - (1/2 * (t.dif %>% cov.g.i %>% suma)))
W2 <- ((t.dif %>% cov.g.i %>% x2) - (1/2 * (t.dif %>% cov.g.i %>% suma)))
W3 <- ((t.dif %>% cov.g.i %>% x3) - (1/2 * (t.dif %>% cov.g.i %>% suma)))
W4 <- ((t.dif %>% cov.g.i %>% x4) - (1/2 * (t.dif %>% cov.g.i %>% suma)))
W5 <- ((t.dif %>% cov.g.i %>% x5) - (1/2 * (t.dif %>% cov.g.i %>% suma)))
W6 <- ((t.dif %>% cov.g.i %>% x6) - (1/2 * (t.dif %>% cov.g.i %>% suma)))
W7 <- ((t.dif %>% cov.g.i %>% x7) - (1/2 * (t.dif %>% cov.g.i %>% suma)))
W8 <- ((t.dif %>% cov.g.i %>% x8) - (1/2 * (t.dif %>% cov.g.i %>% suma)))
W9 <- ((t.dif %>% cov.g.i %>% x9) - (1/2 * (t.dif %>% cov.g.i %>% suma)))
W10 <- ((t.dif %>% cov.g.i %>% x10) - (1/2 * (t.dif %>% cov.g.i %>% suma)))

# Data.frame de las 10 funciones discriminantes
W <- data.frame(W1, W2, W3, W4, W5, W6, W7, W8, W9, W10)

round(W,3) %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)

```

W1	W2	W3	W4	W5	W6	W7	W8	W9	W10
-0.13	-3.245	-5.25	0.634	1.613	1.115	5.9	7.131	3.585	3.992

3. Discriminante - Ida con Tidyverse

Base de datos del ejercicio

```

head(datos2) %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)

```

Nombre	Sexo	LTot	Cint	LEsp	LBra
Alumno 1	F	170	85	43	57
Alumno 2	F	160	80	41	54

Alumno 3	F	156	88	35	48
Alumno 4	F	173	63	53	59
Alumno 5	M	170	86	47	56
Alumno 6	M	165	89	45	61

3.1 Vectores de media

```
# Agrupar por sexo y calcular medias
# across(LTot:LBra, mean) en vez de across(1:4, mean): selecciona por nombre,
# no por posición, así no importa el orden de las columnas
medias <- datos2 %>%
  group_by(Sexo) %>%
  summarise(across(LTot:LBra, mean))

round(medias[,-1], 2) %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)
```

LTot	Cint	LEsp	LBra
161.93	72.14	40.64	59.57
173.30	83.40	52.00	62.50

```
# Vector de diferencia de medias (dif)
dif <- as.matrix(medias[medias$Sexo == "M", -1]) - as.matrix(medias[medias$Sexo
== "F", -1])
dif <- t(dif) # Vector de diferencia de medias transpuesto
dif
```

```
      [,1]
LTot 11.371429
Cint 11.257143
LEsp 11.357143
LBra  2.928571
```

```
# Vector de suma de medias (suma)
suma <- as.matrix(medias[medias$Sexo == "M", -1]) +
as.matrix(medias[medias$Sexo == "F", -1])
suma <- t(suma)
suma
```

```

      [,1]
LTot 335.22857
Cint 155.54286
LEsp  92.64286
LBra 122.07143

```

3.2 Función para automatizar el lda

```

# Función discriminante para todos los estudiantes
# Nota: el resultado se llama "lda_manual" y NO "lda", para no usar el mismo
# nombre de la función MASS::lda() que se usa más adelante en la sección 3.5
# (R sabe diferenciarlos al llamarlos con paréntesis, pero es más claro así)
lda_manual <- datos2 %>%
  dplyr::select(LTot:LBra) %>%
  as.matrix() %>%
  apply(1, function(x) {
    x <- as.matrix(x) # Convertir x a un vector columna (4x1)
    W <- (t(dif) %*% cov.g.i %*% x) - (1/2 * t(dif) %*% cov.g.i %*% suma)
    return(W)
  }) %>%
  tibble(Alumnos = datos2$Nombre, resultados_W = .) %>%           # Nombre
  real, no rownames()
  mutate(Sexo_discriminado = ifelse(resultados_W < 0, "F", "M"),   #
  Discriminante
         Sexo_original      = datos2$Sexo)                       # Sexo
         original

head(lda_manual) %>%
  kbl(booktabs = TRUE, longtable = TRUE) %>%
  kable_classic(full_width = FALSE)

```

Alumnos	resultados_W	Sexo_discriminado	Sexo_original
Alumno 1	-0.1304789	F	F
Alumno 2	-3.2453292	F	F
Alumno 3	-5.2497626	F	F
Alumno 4	0.6343242	M	F
Alumno 5	1.6130084	M	M
Alumno 6	1.1146336	M	M

3.3 Tabla de contingencia

```
# with() evita usar attach(), que modifica el espacio de nombres global
# y puede generar conflictos difíciles de rastrear en sesiones largas
tabla_contingencia <- with(lda_manual,
                           table(Sexo_discriminado, Sexo_original))
tabla_contingencia
```

```
              Sexo_original
Sexo_discriminado  F  M
                F 13  0
                M  1 10
```

```
# Aciertos
aciertos <- sum(diag(tabla_contingencia))
aciertos
```

```
[1] 23
```

```
# Total de estudiantes
total <- sum(tabla_contingencia)
total
```

```
[1] 24
```

```
# Porcentaje de aciertos
aciertos2 <- (aciertos/total) * 100
aciertos2
```

```
[1] 95.83333
```

3.4 Componente gráfico

```
# Grafico de cajas para clasificación inicial
fig_inicial <-
  ggplot(lda_manual, aes(x = Sexo_original,
```

```


        y = resultados_W,
        fill = Sexo_original)) +
geom_boxplot() +
labs(title = "lda para clasificación inicial",
      x = "Sexo Original", y = "Resultados iniciales", fill = "Sexo") +
theme_bw()

# Grafico de cajas para clasificación con el lda
fig_discriminada <-
  ggplot(lda_manual, aes(x = Sexo_discriminado,
                        y = resultados_W,
                        fill = Sexo_discriminado)) +

  geom_boxplot() +
  labs(title = "lda para clasificación con lda",
        x = "Sexo Discriminado", y = "Resultados lda", fill = "Sexo") +
  theme_bw()

# Graficar las dos figuras en un solo panel con patchwork
# (versión ggplot2 de grid.arrange(), sin depender de gridExtra/grid)
fig_inicial + fig_discriminada

```




```

# Figura adicional: ¿a qué estudiantes clasificó bien o mal el lda?
lda_manual <-

```

```
lda_manual %>%
  mutate(Clasificacion = ifelse(Sexo_discriminado == Sexo_original, "Correcta",
    "Incorrecta"))

ggplot(lda_manual, aes(x = Sexo_original,
  y = resultados_W,
  color = Clasificacion)) +
  geom_jitter(width = 0.15, size = 3) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "grey40") +
  scale_color_manual(values = c(Correcta = "#2E8B57", Incorrecta = "#D62728"))
+
  labs(title = "Clasificación individual de cada estudiante (lda manual)",
    x = "Sexo original", y = "Puntaje discriminante (W)",
    color = "Clasificación") +
  theme_bw()
```



3.5 Comparación con la función automatizada MASS::lda()

```
# Función automatizada de análisis discriminante lineal
# (el mismo cierre que prcomp() le dio al taller de PCA: primero a mano, luego
  con la función de R)
modelo_lda <- lda(Sexo ~ LTot + Cint + LEsp + LBra, data = datos2)
```

```
modelo_lda
```

Call:

```
lda(Sexo ~ LTot + Cint + LEsp + LBra, data = datos2)
```

Prior probabilities of groups:

	F	M
	0.5833333	0.4166667

Group means:

	LTot	Cint	LEsp	LBra
F	161.9286	72.14286	40.64286	59.57143
M	173.3000	83.40000	52.00000	62.50000

Coefficients of linear discriminants:

	LD1
LTot	0.04120765
Cint	0.06119582
LEsp	0.14351940
LBra	0.02713046

```
pred_lda <- predict(modelo_lda)
```

```
# Se añade la predicción de MASS::lda() a la tabla de resultados manuales
```

```
lda_manual <- lda_manual %>%
  mutate(Sexo_MASS = pred_lda$class,
         LD1_MASS = as.numeric(pred_lda$x[,1]))
```

```
# Tabla de contingencia y porcentaje de aciertos de MASS::lda()
```

```
tabla_MASS <- with(lda_manual,
                  table(Sexo_MASS, Sexo_original))
tabla_MASS
```


	Sexo_original	
Sexo_MASS	F	M
F	13	0
M	1	10

```
round((sum(diag(tabla_MASS)) / sum(tabla_MASS)) * 100, 1)
```

[1] 95.8

```
# Comparación visual: el discriminante calculado a mano (W) vs el de
# MASS::lda() (LD1)
# Si ambos coinciden en tendencia, es evidencia de que el cálculo manual es
# correcto
ggplot(lda_manual,
       aes(x = resultados_W, y = LD1_MASS, color = Sexo_original)) +
  geom_point(size = 3) +
  labs(title = "Comparación: discriminante manual (Wald-Anderson) vs
  MASS::lda()",
       x = "W manual (Wald-Anderson)", y = "LD1 (MASS::lda())", color = "Sexo")
  +
  theme_bw()
```

Comparación: discriminante manual (Wald-Anderson) vs MASS::lda()



Cuestionario de repaso

Estas preguntas son para trabajar en casa. No tienen una única respuesta «correcta» en el sentido de una

1. ¿Qué papel cumple el vector de diferencia de medias (`dif = promedio.h - promedio.m`) en la fórmula del discriminante de Wald y Anderson? ¿Qué pasaría con el discriminante si hombres y mujeres tuvieran promedios morfométricos casi idénticos?
2. Calcular paso a paso, en R, el puntaje discriminante W para un/a estudiante inventado/a por ti, usando `dif`, `suma` y `cov.g.i` ya calculados en el taller. ¿Lo clasificaría como hombre o mujer? ¿Por qué el signo de W es lo que decide la clasificación?
3. Observar la tabla de contingencia (**Sexo_discriminado** vs **Sexo_original**). ¿Qué tipo de error es más frecuente en sus datos: clasificar a un hombre como mujer, o a una mujer como hombre? Proponer una posible explicación morfométrica de ese error.
4. Comparar el porcentaje de aciertos del modelo manual (Wald-Anderson) con el de `MASS::lda()`. Si los porcentajes son muy parecidos, ¿qué dice eso sobre la fórmula que se calculó a mano?
5. En la figura de aciertos/errores por estudiante (sección 3.4), identificar un estudiante mal clasificado. Revisar sus cuatro medidas morfométricas originales: ¿se parecen más al promedio de su propio sexo o al del sexo opuesto? ¿Qué variable será la que más «confundió» al modelo?